

Relatório: Método do Ponto Fixo

Marcelo Roner
Universidade Federal de Goiás

25 de fevereiro de 2025

Sumário

1	Introdução	2
2	Fundamentação Teórica	2
2.1	Análise de Erro	2
3	Métodos Aplicados	2
4	Implementação Computacional	3
5	Resultados e Discussão	6
6	Conclusão	6
7	Referências	7

1 Introdução

A busca por soluções de equações não lineares $f(x) = 0$ é parte fundamental de inúmeros problemas em engenharia, física, economia e outras áreas. Dentre as diversas técnicas numéricas existentes, o *Método do Ponto Fixo* oferece uma abordagem relativamente simples, mas ilustrativa, para entender o conceito de iteração. A ideia central consiste em reformular a equação $f(x) = 0$ na forma $x = g(x)$, de modo que a raiz do problema seja um ponto fixo da função g .

Este relatório descreve o Método do Ponto Fixo, aborda a teoria de convergência, apresenta sua implementação computacional em Python e discute os resultados obtidos a partir de duas variações do método.

2 Fundamentação Teórica

Seja o problema de determinar x^* tal que $f(x^*) = 0$. Se escrevemos a equação como

$$x = g(x), \quad (1)$$

então x^* será um *ponto fixo* de g , ou seja, $g(x^*) = x^*$. Para construir uma sequência $(x_n)_{n \geq 0}$, definimos

$$x_{n+1} = g(x_n). \quad (2)$$

Condição de Convergência Local: Se existe um intervalo $[a, b]$ contendo x^* tal que $g(x)$ mapeia $[a, b]$ em si mesmo e

$$\max_{x \in [a, b]} |g'(x)| < 1, \quad (3)$$

então a sequência $x_{n+1} = g(x_n)$ converge para o ponto fixo x^* . Intuitivamente, a inclinação de g deve ser pequena o suficiente (em módulo) para que o processo iterativo seja contrativo.

2.1 Análise de Erro

Seja $e_n = x_n - x^*$ o erro na n -ésima iteração. Supondo g derivável em x^* , podemos fazer uma expansão de Taylor:

$$e_{n+1} = x_{n+1} - x^* = g(x_n) - g(x^*) \approx g'(x^*) (x_n - x^*) = g'(x^*) e_n.$$

Assim, $|e_{n+1}| \approx |g'(x^*)| |e_n|$. Portanto, se $|g'(x^*)| < 1$, o erro tende a diminuir geometricamente a cada iteração.

3 Métodos Aplicados

Neste trabalho, comparamos duas formas de definir $g(x)$, partindo da mesma função original $f(x)$:

- **Método 2:** Definimos

$$g(x) = x - \lambda f(x), \quad (4)$$

onde λ é um *parâmetro de relaxação* (ou *step size*), escolhido para tentar satisfazer $|g'(x)| < 1$ em um dado intervalo.

- **Método 3:** Baseia-se em

$$g(x) = x - \frac{f(x)}{f'(x)}, \quad (5)$$

o que é essencialmente o Método de Newton reformulado como um ponto fixo.

O **Método 2** é mais simples e não requer derivadas de f , mas pode ser sensível à escolha de λ . Já o **Método 3** (semelhante ao Newton) tende a apresentar convergência mais rápida, embora dependa do cálculo de $f'(x)$ e, em alguns casos, possa exigir mais cautela perto de pontos onde $f'(x) = 0$.

4 Implementação Computacional

A seguir, apresentamos um trecho de código em Python empregando as bibliotecas *SymPy* (para manipulação simbólica) e *Matplotlib* (para geração de gráficos). O algoritmo faz:

- Verificação da condição de convergência aproximada (3).
- Execução da iteração de ponto fixo conforme a escolha do método.
- Geração de gráficos comparando o número de iterações e a evolução dos erros.

```

1  import numpy as np
2  import sympy as sp
3  import matplotlib.pyplot as plt
4
5  # Definição da função e intervalo
6  x = sp.symbols('x')
7  f_expr = sp.exp(-x) - x
8  intervalo = (0, 2)
9  tol = 1e-6
10 max_iter = 100
11
12 # Derivada da função para o Método 3
13 f_prime = sp.diff(f_expr, x)
14
15 # Lista de valores de lambda para o Método 2
16 lambdas = np.linspace(-2, 2, 40)
17 lambdas = lambdas[lambdas != 0]
18
19 # Função para verificar convergência
20 # Retorna True se |g'(x)| < 1 no intervalo, e g(x) permanece no intervalo
21
22 def verificar_convergencia(g, x, intervalo):
23     a, b = intervalo
24     g_prime = sp.diff(g, x)
25
26     try:
27         g_prime_func = sp.lambdify(x, sp.Abs(g_prime), modules=['numpy'])
28     except:
29         return False
30
31     x_vals = np.linspace(a + 1e-6, b - 1e-6, 1000)
32     try:
33         g_prime_vals = g_prime_func(x_vals)
34         if np.all(np.isfinite(g_prime_vals)) and np.max(g_prime_vals) < 1:

```

```

35         g_func = sp.lambdify(x, g, modules=['numpy'])
36         g_vals = g_func(x_vals)
37         if np.all((g_vals >= a) & (g_vals <= b)) and np.all(np.isfinite(g_vals)):
38             return True
39     else:
40         return False
41 except:
42     return False
43 return False
44
45 # Método do ponto fixo
46
47 def ponto_fixo(g_func, x0, tol=1e-6, max_iter=100):
48     x_n = x0
49     iteracoes = [x_n]
50     for _ in range(max_iter):
51         x_next = g_func(x_n)
52         iteracoes.append(x_next)
53         if abs(x_next - x_n) < tol:
54             return x_next, iteracoes, True
55         x_n = x_next
56     return x_n, iteracoes, False
57
58 # Aplicação do Método 2
59
60 def aplicar_ponto_fixo_metodo2(f_expr, intervalo, x0=None, tol=1e-6, max_iter=100):
61     x = sp.symbols('x')
62     resultados = []
63     for lam in lambdas:
64         g_expr = x - lam * f_expr
65         if verificar_convergencia(g_expr, x, intervalo):
66             g_func = sp.lambdify(x, g_expr, modules=['numpy'])
67             if x0 is None:
68                 x0 = (intervalo[0] + intervalo[1]) / 2
69             raiz, iteracoes, convergiu = ponto_fixo(g_func, x0, tol=tol,
70                 ↪ max_iter=max_iter)
71             num_iter = len(iteracoes) - 1
72             resultados.append({'lambda': lam, 'raiz': raiz, 'iteracoes': iteracoes,
73                 'num_iter': num_iter, 'convergiu': convergiu})
74         else:
75             resultados.append({'lambda': lam, 'raiz': None, 'iteracoes': None,
76                 'num_iter': None, 'convergiu': False})
77     return resultados
78
79 # Aplicação do Método 3
80
81 def aplicar_ponto_fixo_metodo3(f_expr, intervalo, x0=None, tol=1e-6, max_iter=100):
82     x = sp.symbols('x')
83     g_expr = x - f_expr / f_prime
84     if verificar_convergencia(g_expr, x, intervalo):
85         g_func = sp.lambdify(x, g_expr, modules=['numpy'])
86         if x0 is None:
87             x0 = (intervalo[0] + intervalo[1]) / 2
88         raiz, iteracoes, convergiu = ponto_fixo(g_func, x0, tol=tol,
89             ↪ max_iter=max_iter)
90         num_iter = len(iteracoes) - 1
91         return {'raiz': raiz, 'iteracoes': iteracoes, 'num_iter': num_iter,
92             ↪ 'convergiu': convergiu}

```

```

90     else:
91         return None
92
93     # Comparação entre os métodos
94     resultados_metodo2 = aplicar_ponto_fixo_metodo2(f_expr, intervalo)
95     resultado_metodo3 = aplicar_ponto_fixo_metodo3(f_expr, intervalo)
96
97     lambdas_validos = []
98     num_iters_metodo2 = []
99     for res in resultados_metodo2:
100         if res['convergiu']:
101             lambdas_validos.append(res['lambda'])
102             num_iters_metodo2.append(res['num_iter'])
103
104     # Gráfico de comparação (número de iterações vs lambda)
105     plt.figure(figsize=(10, 5))
106     plt.plot(lambdas_validos, num_iters_metodo2, 'o-', label='Método 2')
107     if resultado_metodo3:
108         plt.axhline(y=resultado_metodo3['num_iter'], color='r', linestyle='--',
109             ↪ label='Método 3')
110     plt.xlabel('Lambda')
111     plt.ylabel('Número de Iterações')
112     plt.title('Número de Iterações até Convergência')
113     plt.legend()
114     plt.grid(True)
115     plt.show()
116
117     # Análise detalhada para o melhor lambda do Método 2
118     if resultado_metodo3:
119         best_result_metodo2 = min(resultados_metodo2, key=lambda r: r['num_iter'] if
120             ↪ r['convergiu'] else max_iter)
121         iteracoes_metodo2 = best_result_metodo2['iteracoes']
122         erros_metodo2 = [abs(iteracoes_metodo2[i+1] - iteracoes_metodo2[i]) for i in
123             ↪ range(len(iteracoes_metodo2)-1)]
124
125         iteracoes_metodo3 = resultado_metodo3['iteracoes']
126         erros_metodo3 = [abs(iteracoes_metodo3[i+1] - iteracoes_metodo3[i]) for i in
127             ↪ range(len(iteracoes_metodo3)-1)]
128
129     # Plotagem comparativa
130     fig, axes = plt.subplots(1, 2, figsize=(12, 5))
131
132     # (a) Convergência dos métodos
133     axes[0].plot(range(len(iteracoes_metodo2)), iteracoes_metodo2, marker='o',
134         ↪ linestyle='-',
135         label=f"Método 2 ( = {best_result_metodo2['lambda']:.2f})")
136     axes[0].plot(range(len(iteracoes_metodo3)), iteracoes_metodo3, marker='s',
137         ↪ linestyle='-', label='Método 3')
138     axes[0].set_title('Evolução das Aproximações')
139     axes[0].set_xlabel('Iteração')
140     axes[0].set_ylabel('Aproximação de x')
141     axes[0].grid(True)
142     axes[0].legend()
143
144     # (b) Erro absoluto em escala log
145     axes[1].semilogy(range(1, len(erros_metodo2) + 1), erros_metodo2, marker='o',
146         ↪ linestyle='-',
147         label=f"Método 2 ( = {best_result_metodo2['lambda']:.2f})")

```

```

141 axes[1].semilogy(range(1, len(erros_metodo3) + 1), erros_metodo3, marker='s',
    ↪ linestyle='-', label='Método 3')
142 axes[1].set_title('Erro Absoluto')
143 axes[1].set_xlabel('Iteração')
144 axes[1].set_ylabel('Erro')
145 axes[1].grid(True, which='both', ls='--')
146 axes[1].legend()
147
148 plt.tight_layout()
149 plt.show()

```

5 Resultados e Discussão

Para o exemplo $f(x) = e^{-x} - x$, empregamos o intervalo $(0, 2)$ e variamos λ no Método 2 entre -2 e 2 . A Figura 1 exibe o número de iterações necessário para a convergência em função de λ . Já as Figuras 2-(a) e 2-(b) comparam a evolução das aproximações e o erro absoluto (em escala logarítmica) entre o melhor caso do Método 2 e o Método 3:




Figura 1: Número de iterações para convergência em função de λ (Método 2). A linha tracejada vermelha representa o número de iterações do Método 3, que não depende de λ .

Observamos que o Método 3 (inspirado no Método de Newton) convergiu mais rápido e, sobretudo, de maneira independente do parâmetro λ . Por outro lado, o Método 2 pode atingir convergência satisfatória se λ for bem escolhido, mas exibe forte sensibilidade a esse valor.

6 Conclusão

O **Método do Ponto Fixo** oferece uma base importante para compreender métodos iterativos na resolução de equações não lineares. A forma da função $g(x)$ determina a robustez e a velocidade de convergência do processo. Em termos de aplicação:

- O **Método 2** (Equação (4)) exige apenas a avaliação de $f(x)$, mas a escolha do parâmetro λ é crucial para garantir $|g'(x)| < 1$ e um bom desempenho.

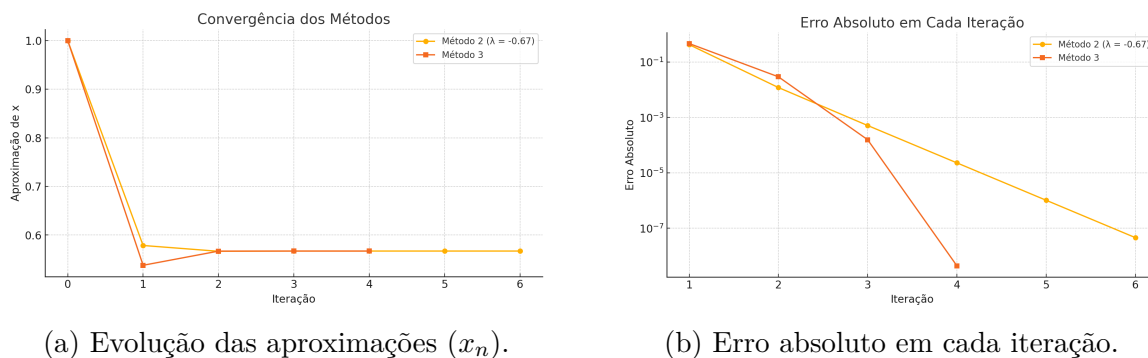


Figura 2: Comparação entre o melhor caso do Método 2 e o Método 3. (a) Evolução de x_n ao longo das iterações. (b) Decaimento do erro absoluto em escala logarítmica.

- O **Método 3** (Equação (5)) costuma apresentar convergência mais rápida (semelhante ao Método de Newton), porém depende do cálculo de $f'(x)$ e pode falhar se $f'(x^*) \approx 0$ ou se a escolha inicial x_0 não estiver em uma região de convergência.

Para problemas de grande porte ou funções mais complexas, combinações de estratégias (como *line search* ou *regularizações*) podem ser necessárias. Ainda assim, a análise mostrada aqui ilustra como pequenas variações em $g(x)$ podem produzir comportamentos distintos de convergência.

7 Referências

Referências

- [1] Jaan Kiusalaas, *Numerical Methods in Engineering with Python*, Cambridge University Press, 2005.
- [2] N. B. Franco, *Cálculo Numérico*, Pearson Prentice Hall, 2007.
- [3] S. Lynch, *Dynamical Systems with Applications Using Python*, Springer, 2018.
- [4] M. A. G. Ruggiero, V. L. Lopes, *Cálculo Numérico: aspectos teóricos e computacionais*, Makron Books, 1997.